MINISTÉRIO DA EDUCAÇÃO
SECRETARIA DE EDUCAÇÃO PROFISSIONAL E TECNOLÓGICA
INSTITUTO FEDERAL DO NORTE DE MINAS GERAIS – IFNMG
Criado pela Lei no.11.892, de 29/12/2008
Campus Montes Claros

JOÃO KENNEDY SOUZA SOARES

RELATÓRIO : Algoritmo Genético (AG) para o problema "N – Rainhas"

Relatório apresentado ao Professor Laércio Ives Santos como parte das exigências de avaliação da disciplina de Computação Natural do Curso de Bacharelado em Ciência da Computação do Instituto Federal do Norte de Minas Gerais, Campus Montes Claros.

MONTES CLAROS - MG

2026

Resumo

Este trabalho apresenta a implementação de um Algoritmo Genético (AG) para o problema das N-Rainhas e a avaliação de diferentes formas de atualização da população. O problema consiste em posicionar N rainhas em um tabuleiro N x N sem conflitos de ataque. Foi adotada representação por permutação, seleção por torneio, cruzamento por ponto de corte e mutação por troca de posições. A primeira etapa experimental analisou o comportamento do AG baseado em instâncias n = 8, 15, 20 e 30. A segunda etapa comparou seis métodos de atualização populacional para n = 30, com 30 repetições por método. Os resultados indicam bom desempenho do AG em instâncias pequenas e médias, com aumento de dificuldade em n = 30. Na comparação entre estratégias, abordagens baseadas em qualidade de sobrevivência superaram seleção aleatória de sobreviventes. Conclui-se que o mecanismo de atualização da população influencia fortemente a qualidade final e a convergência do AG.

Palavras-chave: algoritmo genético; n-rainhas; otimização combinatória; elitismo; atualização populacional.

1. Introdução

O problema das N-Rainhas é uma formulação clássica de otimização combinatória e, ao mesmo tempo, um benchmark tradicional para avaliação de métodos heurísticos e metaheurísticos. Dado um tabuleiro N x N, busca-se posicionar N rainhas de modo que nenhuma delas esteja sob ataque de outra, o que exige satisfazer simultaneamente restrições de linha, coluna e diagonal. Embora a definição seja simples, o custo computacional associado a busca de soluções aumenta rapidamente com N, tornando o problema particularmente relevante para estudos sobre eficiência algorítmica em espaços de busca de alta cardinalidade.

No contexto deste trabalho, a importância do problema não reside apenas em encontrar uma configuração válida, mas em analisar como as escolhas tomadas no Algoritmo Genético influenciam a capacidade de convergência em instâncias mais complexas. Como o número de arranjos possíveis cresce em ordem fatorial. Dessa forma, a aplicação de um AG se justifica por sua capacidade de equilibrar a exploração por meio de operadores estatísticos, buscando boas soluções em tempo computacional.

Partindo dessa motivação, este estudo foi estruturado em duas frentes complementares: inicialmente, analisou-se o comportamento do AG base em diferentes instâncias, com foco na evolução da aptidão, taxa de sucesso e custo computacional; em seguida, compararam-se estratégias de atualização populacional, com o objetivo de investigar a qualidade final das soluções e a velocidade de convergência. A contribuição central do trabalho consiste, portanto, em apresentar uma implementação funcional do AG para N-Rainhas e discutir criticamente seus resultados, evidenciando

tanto os ganhos obtidos quanto às limitações que aparecem em instâncias mais desafiadoras.

2. Materiais e Métodos

Os experimentos foram desenvolvidos em Python, com apoio das bibliotecas numpy, random, time e matplotlib, em ambiente de notebook Jupyter. O problema foi modelado por representação em permutação, na qual cada indivíduo $I = [c0, c1, ..., cN-1]$ codifica a coluna ci ocupada pela rainha na linha i. Essa escolha garante, por construção, ausência de conflitos em linha e coluna, concentrando a função objetivo e nos ataques diagonais. A aptidão foi definida como o número total de pares (i, j), com $i < j$, que satisfazem $|i - j| = |ci - cj|$. Dessa forma, o problema é tratado como minimização, sendo ótima a solução para a qual $f(I) = 0$.

O Algoritmo Genético foi estruturado de forma a garantir coerência entre a representação dos indivíduos e os operadores evolutivos, assegurando a validade das soluções ao longo do processo de evolução, na qual a função calcular aptidão estabelece o critério de qualidade ao contabilizar conflitos diagonais; quanto menor esse valor, melhor o indivíduo. A seleção de pais ocorre através do torneio binário, na qual dois candidatos são sorteados e o menos conflitante é escolhido, o que introduz pressão seletiva sem eliminar completamente a aleatoriedade. O cruzamento utiliza ponto de corte com reconstrução por genes não repetidos para preservar a viabilidade da permutação, enquanto a mutação realiza troca de duas posições com probabilidade 0,05 mantendo diversidade genética e reduzindo estagnação prematura.

A dinâmica evolutiva completa e executada em ciclos geracionais. Em cada geração, calcula-se a aptidão da população, registram-se os indicadores de melhor e média de fitness e verifica-se a condição de parada por conflito zero. Quando essa condição não é atingida, forma-se a próxima população pela repetição do ciclo seleção, cruzamento e mutação. Na configuração base, adotou-se a substituição total entre gerações, de modo que os filhos passam a compor integralmente a população seguinte. Essa decisão simplifica o comportamento do algoritmo, mas pode descartar indivíduos de alta qualidade na ausência de elitismo.

O experimento base analisou o efeito do aumento de complexidade com controle de variáveis. Foram avaliadas as instâncias *(n = 8, 15, 20 e 30)*, mantendo-se fixos o tamanho populacional *(50)*, o limite de gerações *(50)* e o número de repetições *(30 por instância)*. Com essa padronização, a comparação entre cenários passa a refletir

predominantemente o crescimento do espaço de busca, e não mudanças de parametrização.

Na versão alternativa, a base algoritmo foi mantida e variou-se apenas a etapa de sobrevivência para isolar o efeito da atualização populacional. Foram comparadas seis formas, como a substituição total sem elitismo descarta totalmente os pais e maximiza renovação do filhos, substituição total com elitismo preserva o melhor pai e renova o restante, a outra alternativa mantém os k melhores pais com inserção de N-k filhos o que equilibra com melhores, com exploração por novos descendentes, já a inserção dos k melhores filhos em substituição aos piores pais sendo uma atualização mais conservadora, com troca parcial orientada por qualidade, já a seleção dos N melhores na união entre pais e filhos faz uma competição global entre gerações, com foco na seletiva) e a seleção aleatória. Os testes foram realizados para n = 30, com população 50, limite de 80 gerações, taxa de mutação 0,05, 30 repetições e k = 5 (quantidade de indivíduos fixa sem alteração). A avaliação considerou conflito final, taxa de sucesso, evolução do melhor fitness, distribuição de conflitos na população final e, no AG base, tempo médio e número médio de gerações, permitindo analisar simultaneamente qualidade, estabilidade e custo computacional.

3. Resultados e Discussão

3.1 Comportamento do AG versão básica

Os resultados do AG base evidenciam uma degradação progressiva de desempenho conforme a instância aumenta. A Tabela 1 mostra que, para n = 8, o método apresentou alta efetividade, com taxa de sucesso de 80,00%, tempo médio de 0,0075 s e 14,77 gerações médias, indicando convergência relativamente rápida para soluções ótimas. Quando a instância cresce para n = 15, observa-se mudança de comportamento: a taxa de sucesso cai para 13,33%, o número médio de gerações sobe para 46,77 e o tempo médio aumenta para 0,0702 s, mostrando que a mesma parametrização passa a operar próxima do limite de 50 gerações. Em n = 20 e n = 30, a taxa de sucesso foi 0,00%, com 50,00 gerações médias em ambos os casos e tempos médios de 0,1261 s e 0,2728 s, respectivamente. Pela métrica de conflito médio final, também se observa piora progressiva da qualidade das soluções (0,20 em n = 8; 1,47 em n = 15; 2,60 em n = 20; 5,37 em n = 30). Esse comportamento indica saturação do critério de parada por gerações e maior dificuldade de atingir f(I)

= 0 nas instâncias maiores sob os parâmetros atuais.

Tabela 1 - Resultados quantitativos do AG base.

n	Tempo médio (s)	Gerações médias	Taxa de sucesso (%)	Conflito médio final
8	0,0075	14,77	80,00	0,20
15	0,0702	46,77	13,33	1,47
20	0,1261	50,00	0,00	2,60
30	0,2728	50,00	0,00	5,37

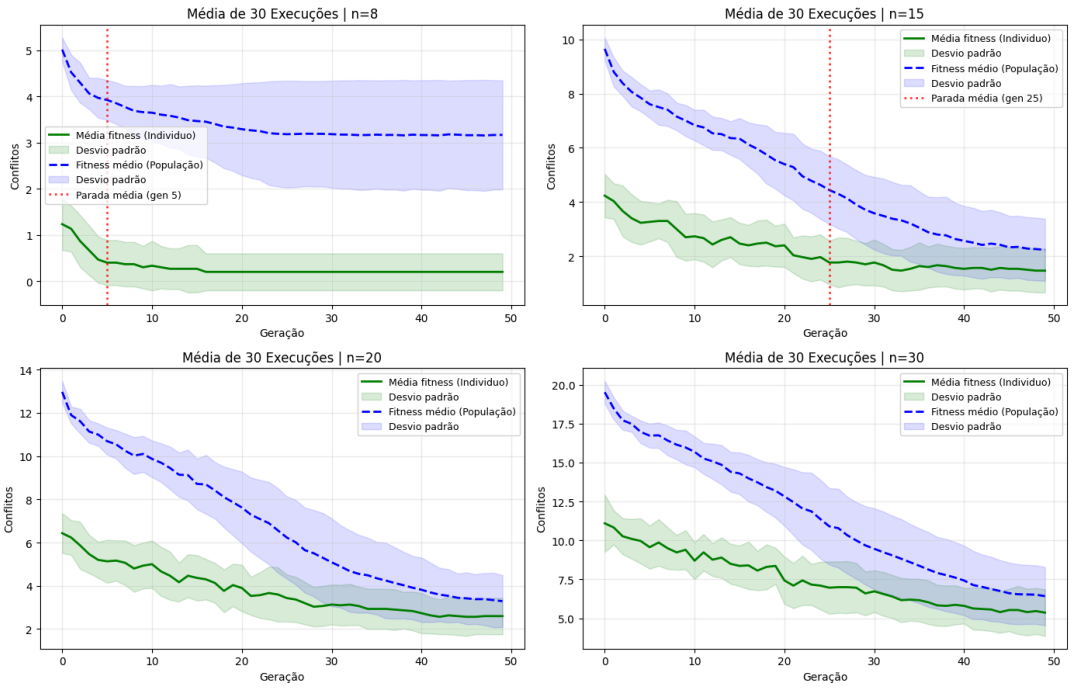

Figura 1 - Curvas de convergência média do AG base por instância.

A Figura 1 reforça essa leitura ao mostrar dois fenômenos simultâneos como redução consistente do conflito médio ao longo das gerações e diminuição da taxa de melhoria nas instâncias mais complexas. Em n = 8, a curva do melhor indivíduo se aproxima rapidamente de zero, o que é compatível com a alta taxa de sucesso medida. Em n = 15, a convergência permanece presente, mas mais lenta e com maior variabilidade. Já em n = 20 e n = 30, as curvas mantêm declive descendente, porém estabiliza em níveis superiores ao último, sugerindo estagnação em regiões subótimas do espaço de busca.

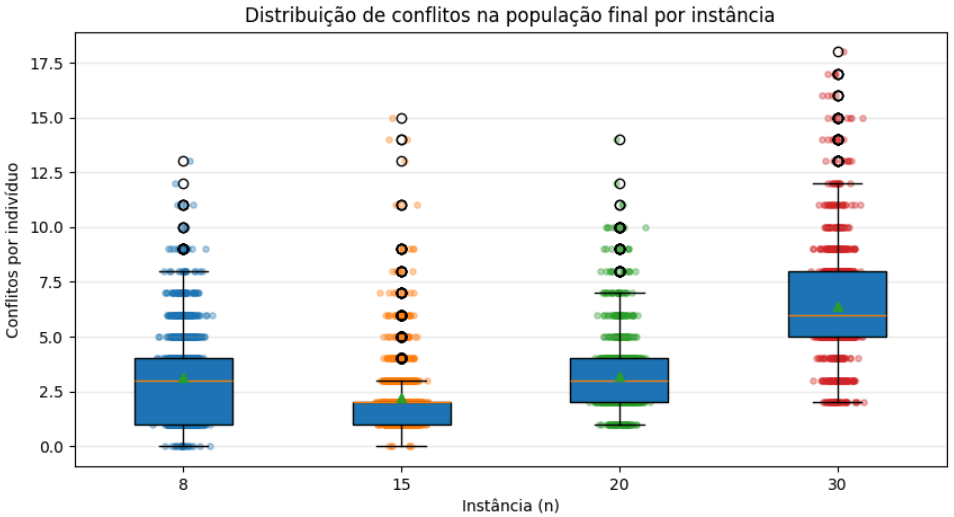

Figura 2 - Distribuição de conflitos finais por instância.

A Figura 2 mostra que a distribuição de conflitos finais acompanha o aumento de complexidade: as medianas e a dispersão crescem com N, e para n = 30 concentra os maiores valores, com maior presença de casos distantes da otimalidade. Esse resultado é coerente com a queda da taxa de sucesso observada na tabela comparativa e indica que, nas instâncias mais difíceis, não apenas o melhor indivíduo final piora, mas também a qualidade global da população remanescente.

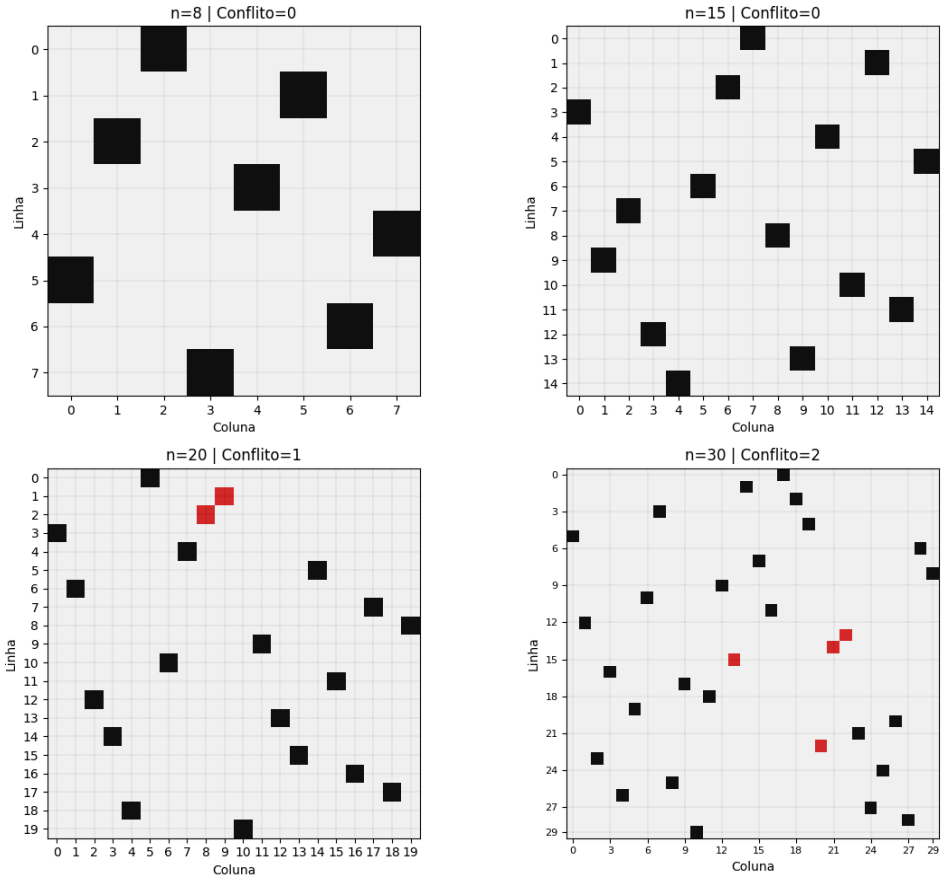

Figura 3 - Melhores tabuleiros por instância.

A Figura 3 confirma esse padrão: os melhores tabuleiros de n = 8 e n = 15 atingiram conflito 0, enquanto as melhores soluções de n = 20 e n = 30 permaneceram com conflitos residuais 1 e 2. Assim, o algoritmo implementado demonstra boa capacidade de busca para instâncias pequenas e médias, mas requer ajuste de parâmetros para manter a mesma eficácia em instâncias maiores.

3.2 Comportamento do AG versão Alternativa

Na comparação entre métodos de atualização para n = 30 (30 repetições por método), nenhuma estratégia alcançou taxa de sucesso diferente de 0,00%, o que confirma que a instância, nessa configuração experimental, é desafiadora para o número de gerações adotada. Ainda assim, houve diferença relevante na qualidade média das soluções finais. Conforme a Tabela 2, as menores médias de conflito foram obtidas por "Melhores dos N melhores união (P+F)" (2,93), seguida por "k melhores pais + N-k filhos" (3,03) e "Substituição total com elitismo" (3,23). Em seguida apareceram "Somente k melhores filhos" (3,53) e "Substituição total sem elitismo" (4,30). O pior resultado foi "Seleção Aleatória da União (P+F)", com média 6,30. Pela métrica de desvio padrão, a menor dispersão foi observada em "k melhores pais + N-k filhos" (0,75), enquanto a maior variabilidade ocorreu em "Seleção Aleatória da União (P+F)" (1,37), reforçando a menor estabilidade do método aleatório.

Tabela 2 - Comparação dos métodos de atualização populacional (n = 30).

Método	Taxa de sucesso (%)	Média de conflitos	Desvio padrão
Substituição total sem elitismo	0,00	4,30	1,07
Substituição total com elitismo	0,00	3,23	0,96
k melhores pais + N-k filhos	0,00	3,03	0,75
Somente k melhores filhos	0,00	3,53	1,06
Melhores dos N melhores união (P+F)	0,00	0,00	0,96
Seleção Aleatória da União (P+F)	0,00	0,00	1,37

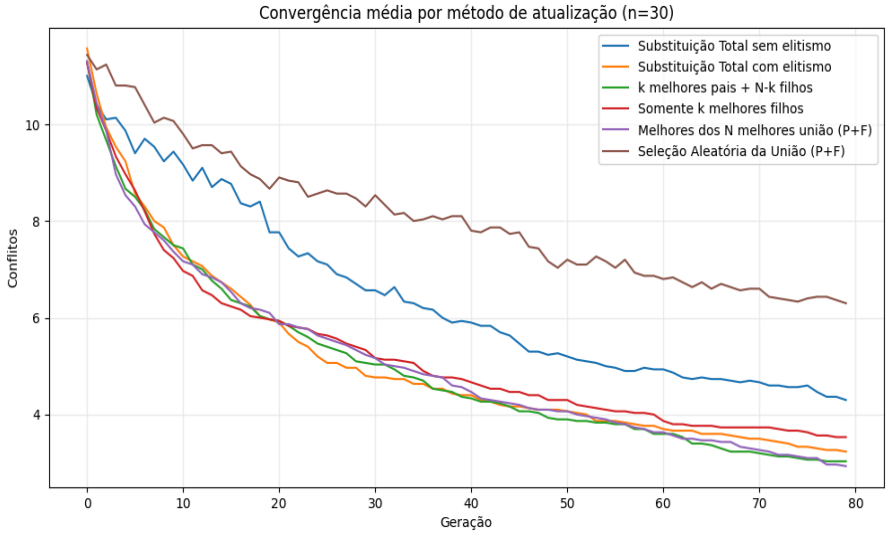

Figura 4 - Comparação dos métodos de atualização para n = 30.

As curvas da Figura 4 são consistentes com esses valores finais e mostram que métodos com critério de qualidade a cada geração apresentam convergência mais acentuada. Em contrapartida, a estratégia aleatória preserva variabilidade, mas reduz a pressão evolutiva sobre indivíduos mais aptos, retardando a descida da curva e mantendo conflitos finais mais altos. Em termos práticos, os resultados indicam que a política de atualização populacional é uma decisão estrutural do algoritmo, com impacto direto na eficiência da busca.

4. Conclusão

Os resultados obtidos permitem concluir que o algoritmo genético implementado foi adequado para atacar o problema das N-Rainhas e apresentou comportamento consistente com a complexidade esperada da tarefa. Na etapa base, observou-se alta efetividade para instâncias menores e degradação progressiva de desempenho com o aumento de N, evidenciando que a combinação de parâmetros utilizada é suficiente para cenários menos complexos, mas passa a ser limitada quando o espaço de busca cresce substancialmente.

Na versão alternativa, a comparação entre cada geração mostrou que o mecanismo de atualização populacional é um fator estrutural do desempenho do AG. Estratégias orientadas por qualidade, como as que preservam elite ou promovem competição global entre pais e filhos, tendem a produzir melhores trajetórias de convergência do que abordagens com forte componente aleatório. Esses resultados reforçam, que cada geração é um método de execução que pode ser decisivo em instâncias maiores.

5. Referências

CASTRO, Leandro Nunes de. **Fundamentals of natural computing: basic concepts, algorithms, and applications.** Boca Raton: Chapman & Hall/CRC, 2006.

CASTRO, Leandro Nunes de. **Computação natural: uma jornada ilustrada.** São Paulo: Livraria da Física.

EIBEN, A. E.; SMITH, J. E. **Introduction to evolutionary computing.** 2. ed. Berlin: Springer, 2015.

COMPUTAÇÃO EVOLUCIONÁRIA (ALGORITMOS GENÉTICOS). Material didático em PDF.